Введение в обработку естественного языка на Python

Русаков Алексей

vk.com/RusAlm github.com/RusAl84/text_mining

Системы мгновенного обмена сообщениями

Отчеты

Социальные сети

Документы

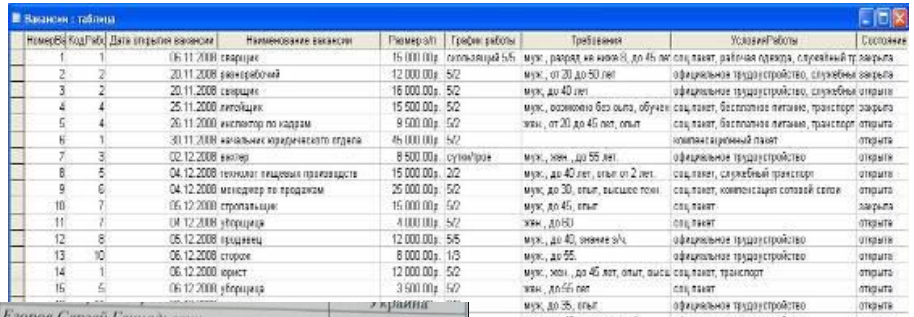

10	Егоров Сергей Геннадьевич	РФ
11	Ежов Станислав Станиславович	Украина
12	Еремин Николай Николаевич	Украина
13	Жидких Аркадий Юрьевич	РФ
14	Кимаковский Игорь Владимирович	РФ
15	Ковалис Ольга Валерьевна	РФ
16	Кореновский Дмитрий Евстафьевич	Украина
17	Костенко Андрей Сергеевич	Украина
18	Лазарев Сергей Александрович	Украина
19	Ломако Юрий Николаевич	Украина
20	Мельничук Петр Николаевич	Молдова
21	Мефедов Евгений Игоровичч	РФ
22	Одинцов Максим Евгеньевич	РФ
23	Никалов Валерий Валерьевич	Украина
24	Просолова Юлия Вадимовна	Украина
25	Ракушин Александр Сергеевич	Украина
26	Родионова Антонина Петровна	Украина
27	Саттаров Александр Валерьевич	Украина
28	Седиков Алексей Сергеевич	РФ
29	Сидоров Денис Владимирович	РФ
30	Тарасенко Александр Сергеевич	Украина
31	Фёдоров Виктор Андреевич	Украина
32	Хитров Денис Васильевич	Украина
33	Хоменко Олег Юрьевич	Украина
34	Цемах Владимир Борисович	Украина

4	Bean Goose	Anser fabalis	Metsähanhi
5	Pink-footed Goose	Anser brachyrhynchus	Lyhytnokkahanhi
6	Greater White-fronted Goose	Anser albifrons	Tundrahanhi
7	Lesser White-fronted Goose	Anser erythropus	Kiljuhanhi
8	Greylag Goose	Anser anser	Merihanhi
9	Snow Goose	Anser caerulescens	Lumihanhi
10	Canada Goose	Branta canadensis	Kanadanhanhi (Cat. C)
11	Barnacle Goose	Branta leucopsis	Valkoposkihanhi
12	Brent Goose	Branta bernicla	Sepelhanhi
13	Red-breasted Goose	Branta ruficollis	Punakaulahanhi
14	Ruddy Shelduck	Tadorna ferruginea	Ruostesorsa
15	Common Shelduck	Tadorna tadorna	Ristisorsa
16	Mandarin Duck	Aix galericulata	Mandariinisorsa (Cat. C)
17	Eurasian Wigeon	Anas penelope	Haapana
18	American Wigeon	Anas americana	Amerikanhaapana
19	Gadwall	Anas strepera	Harmaasorsa
20	Common Teal	Anas crecca	Tavi
21	Green-winged Teal	Anas carolinensis	Amerikantavi
22	Mallard	Anas platyrhynchos	Sinisorsa
23	American Black Duck	Anas rubripes	Nokisorsa
24	Northern Pintail	Anas acuta	Jouhisorsa
25	Garganey	Anas querquedula	Heinätavi

Таблицы и списки (ненаглядно и неудобно)

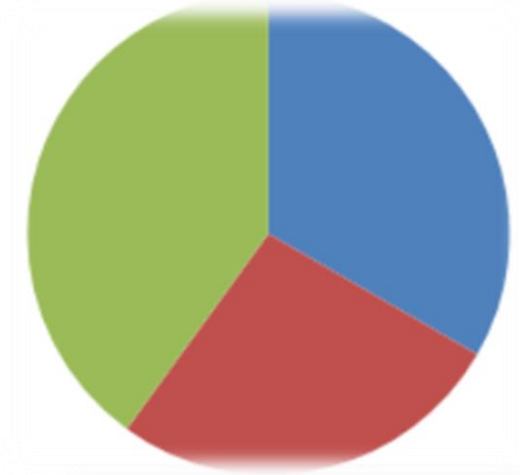

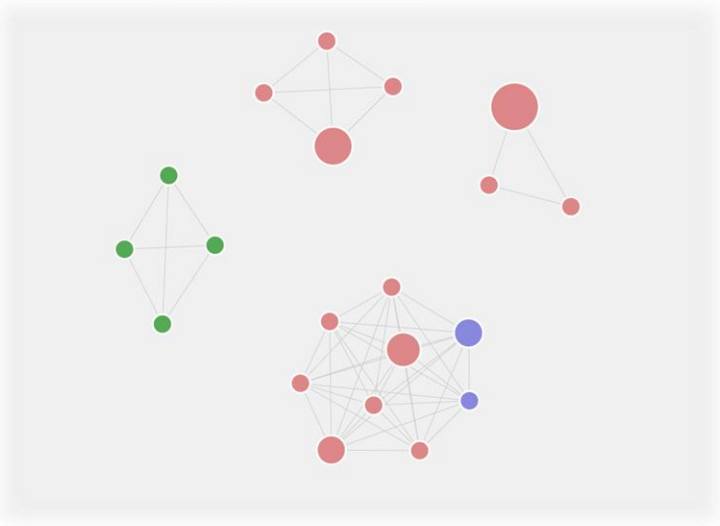

Визуализация

Статистические свойства коллекций

- Перед тем, как анализировать коллекцию текстов, необходимо узнать её статистические свойства
- Каждая задача требует подсчёта специфичных ей величин.
- Есть характеристики, на которые нужно смотреть всегда:
  - Частоты слов в коллекции, закон Ципфа
  - Гистограмма длин документов
  - Закон Хипса для документов

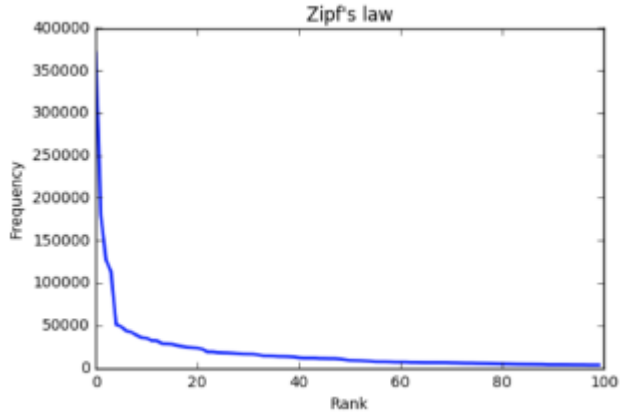

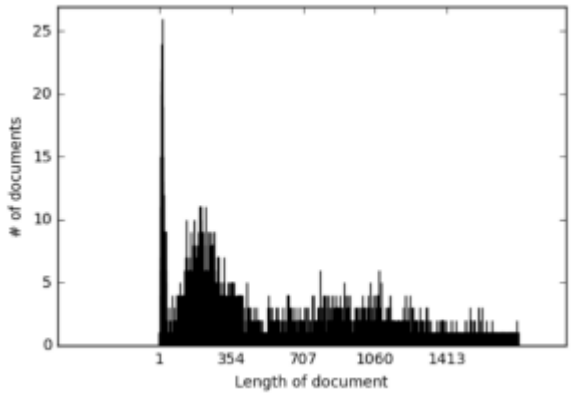

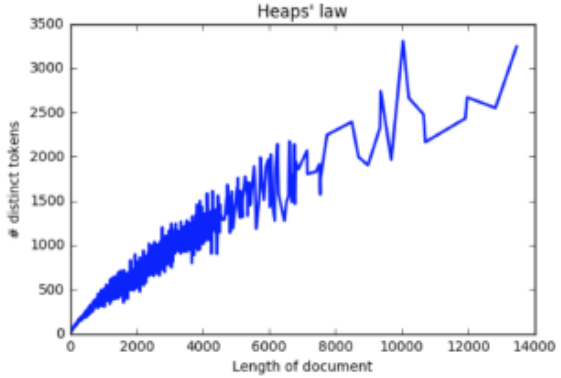

Зако́н Ци́пфа

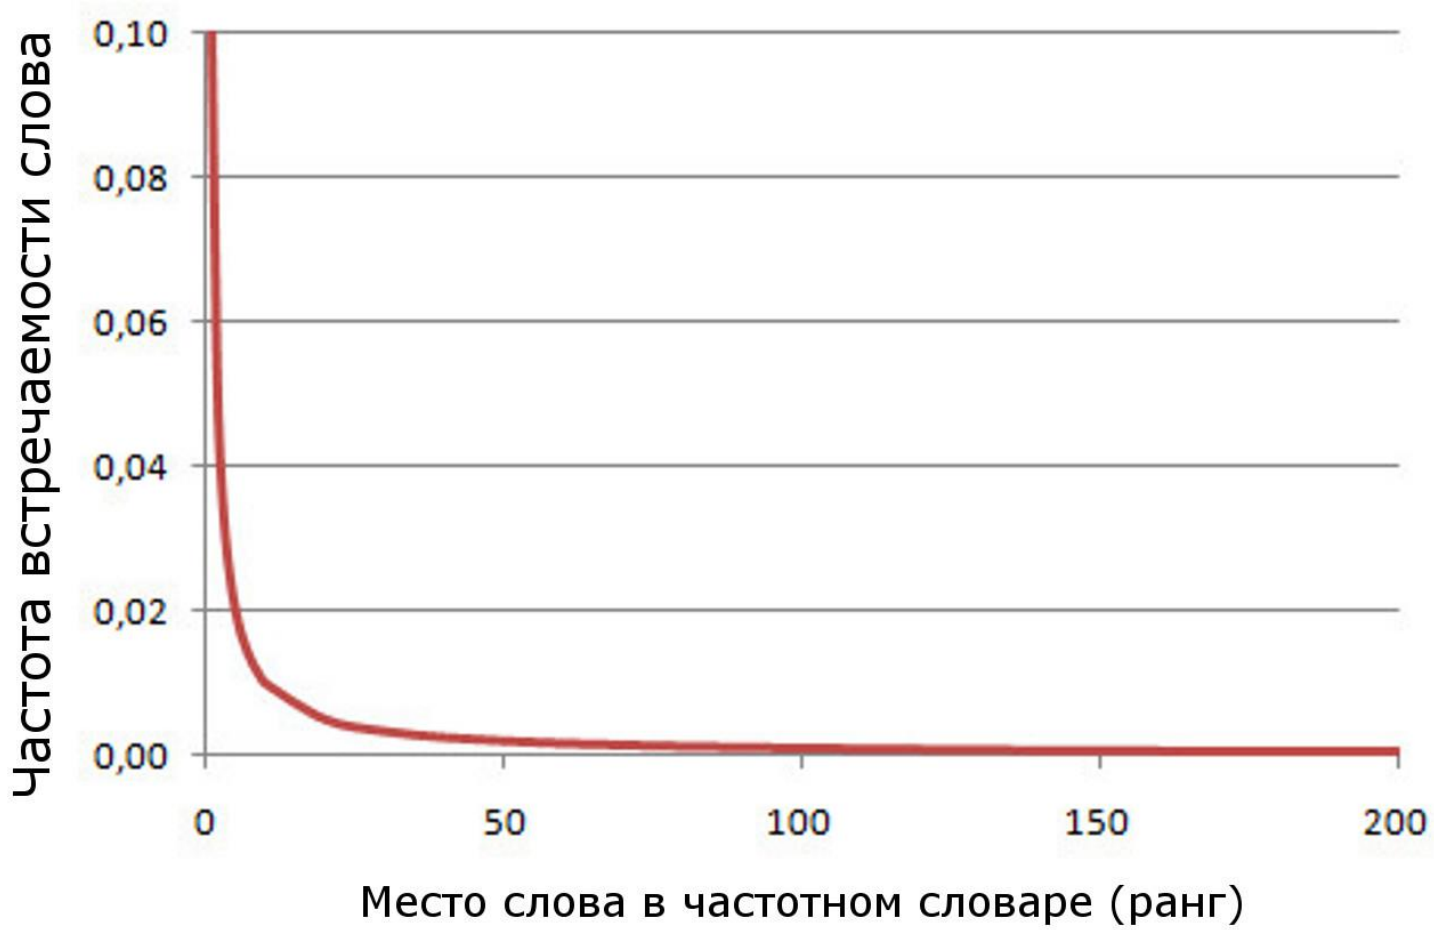
Частота встречаемости слова
0,10
0,08
0,06
0,04
0,02
0,00
0
50
100
150
200
Место слова в частотном словаре (ранг)

Закон Хипса для документов

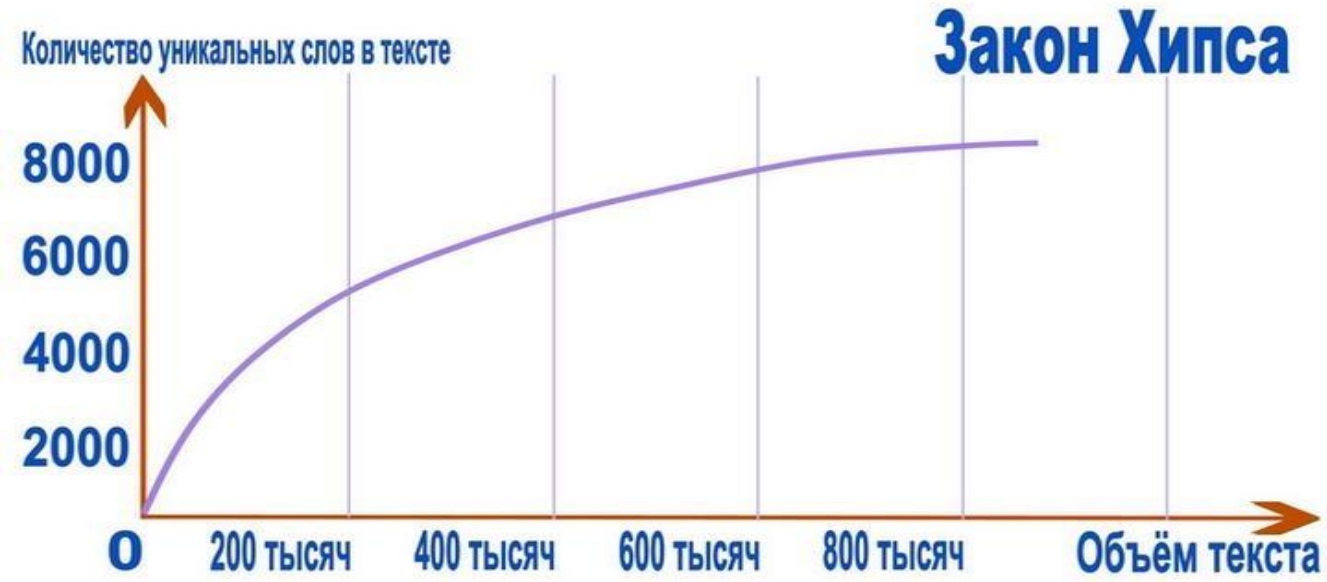

$$v_R(n) = Kn^{\beta}$$

где *v* — это объем словаря уникальных слов, составленный из текста, который состоит из *n* уникальных слов,
α и β — определенные эмпирически параметры.
Для европейских языков α принимает значение от 10 до 100, а β — от 0.4 до 0.6.

Классический случай подхода TF*IDF

$$TF = \frac{n_i}{\sum_k n_k}$$

где n_i - количество употреблений i-й N-граммы, знаменатель – общая длина документа в словах

$$IDF = \log \frac{D}{DF_i}$$

где D – общее количество документов в коллекции,
знаменатель - число документов, содержащих i-й N-грамму

Предобработка текста

- Первый шаг любой аналитики – получение данных. Предположим, что данные есть в некотором подходящем для работы формате.
- Следующая задача – предобработка
- Базовые шаги предобработки:
  1. токенизация
  2. приведение к нижнему регистру
  3. удаление стоп-слов
  4. удаление пунктуации
  5. фильтрация по частоте/длине/соответствию регулярному выражению
  6. лемматизация или стемминг
- Чаще всего применяются все эти шаги, но в разных задачах какие-то могут опускаться, поскольку приводят к потере информации.

Полезные модули

- **nltk** — один из основных модулей Python для анализа текстов, содержит множество инструментов.
- **re/regex** — модули для работы с регулярными выражениями
- **pymorphy2/pymystem3** — лемматизаторы
- Специализированные модули для обучения моделей (например, CRF)
- **numpy/pandas/scipy** — модули общего назначения
- **Scikit-learn** - самый распространенный выбор для решения задач классического машинного обучения. Использовали для TF-IDF
- **GENSIM** - библиотека обработки естественного языка, предназначенная для «Тематического моделирования».
- **FastText** -это библиотека, содержащая предобученные готовые векторные представления слов (читать, что это такое) и классификатор, то есть алгоритм машинного обучения, разбивающий слова на классы.
- **Word2vec** -Библиотека word2vec – это инструмент (набор алгоритмов) для расчета векторных представлений слов, реализует две основные архитектуры – Continuous Bag of Words (CBOW) и Skip-gram. На вход подается корпус текста, а на выходе получается набор векторов слов.

https://www.elibrary.ru/item.asp?id=44545625

Токенизация, удаление стоп-слов и пунктуации

- В nltk есть разные токенизаторы:
  - RegexpTokenizer
  - BlanklineTokenizer
  - И ещё около десятка штук
- Стоп-слова тоже можно удалять с помощью nltk (но лучше дополнительно фильтровать вручную):

```
from nltk.corpus import stopwords
words = [word for word in word_list
    if word not in stopwords.words('russian')]
```

- Пунктуацию можно удалять с помощью регулярных выражений, а можно просто:

```
from string import punctuation
s = ''.join(c for c in s if c not in punctuation)
```

Тематическое моделирование

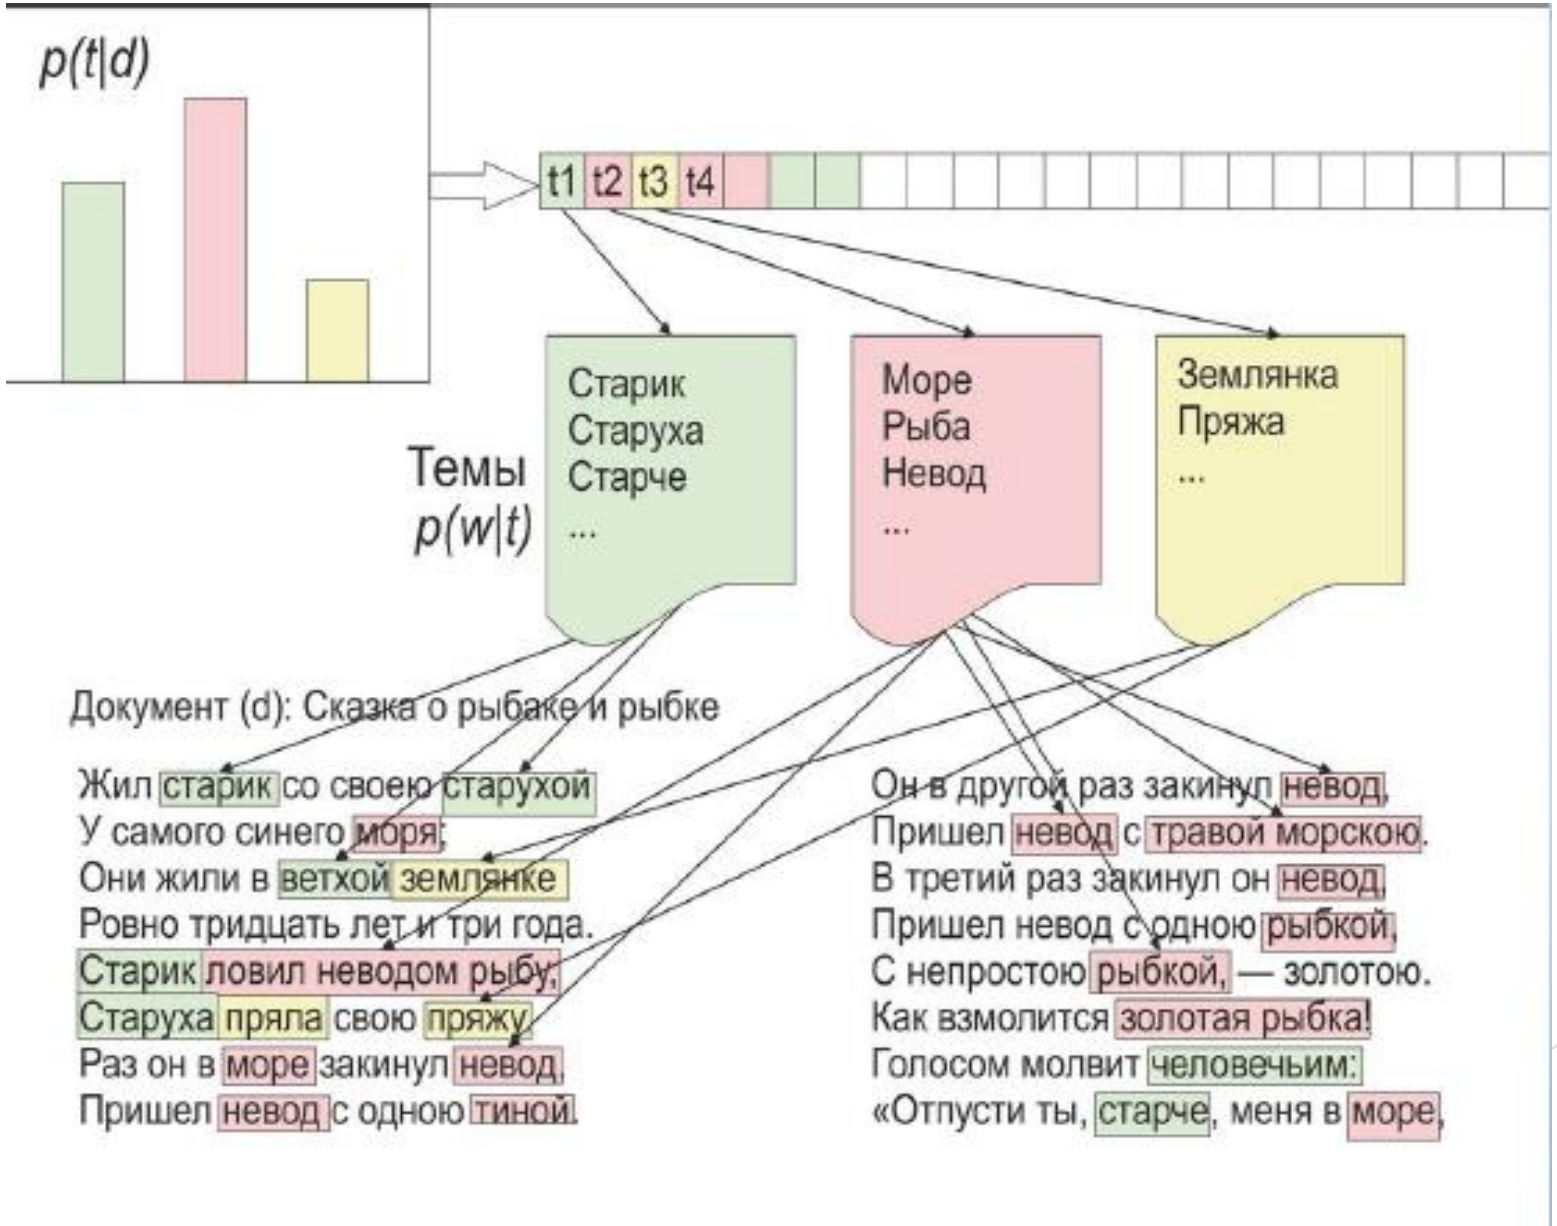

Спасибо за внимание!

Русаков Алексей

vk.com/RusAlM t.me/RusAl84

Современные библиотеки Python

Gensim

Gensim — библиотека обработки естественного языка предназначения для «Тематического моделирования». С его помощью можно обрабатывать тексты, работать с векторными моделями слов (такими как Word2Vec, FastText и т. д.) и создавать тематические модели текстов.

Тематическое моделирование — это метод извлечения основных тем которым посвящен обрабатываемый текст. В пакете Gensim реализованы основные алгоритмы тематического моделирования: скрытое распределение Дирихле (LDA) и скрытое семантическое индексирование (LSI).

Какие типы текстов может обрабатывать Gensim? Входной текст может быть в одной из 3 разных форм:

- Как предложения, хранящиеся в собственном объекте списка Python.
- Как один текстовый файл.
- В нескольких текстовых файлах.

Документация на английском языке:
https://radimrehurek.com/gensim/auto_examples/index.html#documentation

Руководство для начинающих на русском языке:
https://webdevblog.ru/gensim-rukovodstvo-dlya-nachinajushhih/

Word2vec

Word2vec — это инструмент (набор алгоритмов) для расчета векторных представлений слов, реализует две основные архитектуры — Continuous Bag of Words (CBOW) и Skip-gram. На вход подается корпус текста, а на выходе получается набор векторов слов.

Принцип работы:
Нахождение связей между контекстами слов согласно предположению, что слова, находящиеся в похожих контекстах, имеют тенденцию значить похожие вещи, т.е. быть семантически близкими. Более формально задача стоит так: максимизация косинусной близости между векторами слов (скалярное произведение векторов), которые появляются рядом друг с другом, и минимизация косинусной близости между векторами слов, которые не появляются друг рядом с другом. Рядом друг с другом в данном случае значит в близких контекстах.

FastText

FastText — это библиотека, содержащая предобученные готовые векторные представления слов и классификатор, то есть алгоритм машинного обучения разбивающий слова на классы. FastText разработала команда исследователей из Facebook AI Research, в составе которых был и создатель Word2vec Томаш Миколов

Так что же отличает FastText? Более быстрая работа по сравнению с другими пакетами и моделями. Для модели векторных представлений слов используется skip-gram с негативным сэмплированием. Негативное сэмплирование — это способ создать для обучения векторной модели отрицательные примеры, то есть показать ей пары слов, которые не являются соседями по контексту. Для каждого положительного примера (когда слова в тексте стоят рядом, например, «пушистый котик») мы подбираем несколько отрицательных («пушистый утюг», «пушистый радиосигнал», «пушистое бегство»). Всего подбирается от 3 до 20 случайных слов. Такой случайный подбор нескольких примеров не требует много компьютерного времени и позволяет ускорить работу FastText.

Документация на английском языке: https://fasttext.cc/docs/en/supervised-tutorial.html

pymorphy2

Pymorphy2 – морфологический анализатор. Он умеет:

- приводить слово к нормальной форме (например, “люди -> человек”, или “гулял -> гулять”).
- ставить слово в нужную форму. Например, ставить слово во множественное число, менять падеж слова и т.д.
- возвращать грамматическую информацию о слове (число, род, падеж, часть речи и т.д.)

При работе используется словарь OpenCorpora; для незнакомых слов строятся гипотезы. Библиотека достаточно быстрая: в настоящий момент скорость работы - от нескольких тыс слов/сек до > 100тыс слов/сек (в зависимости от выполняемой операции, интерпретатора и установленных пакетов); потребление памяти - 10...20Мб; полностью поддерживается буква ё. Лицензия - MIT.

Документация на русском языке:
https://pymorphy2.readthedocs.io/en/stable/user/index.html

NLTK

NLTK (Natural Language Toolkit) — это важная библиотека, поддерживающая такие задачи, как классификация, стемминг, маркировка, синтаксический анализ и семантическое рассуждение в Python. Это бесплатный проект с открытым исходным кодом, поддерживающийся в данный момент.

Благодаря практическому руководству, представляющему основы программирования наряду с темами вычислительной лингвистики, а также исчерпывающей документации по API, NLTK подходит как для лингвистов, инженеров, студентов, преподавателей, исследователей, так и для обычных пользователей. NLTK доступен для Windows, Mac OS X и Linux.

Установка и документация на английском языке: https://www.nltk.org/

spaCy

spaCy – это бесплатная библиотека с открытым исходным кодом для расширенной обработки естественного языка в Python.

spaCy разработан специально для производственного использования и помогает создавать приложения, обрабатывающие и «понимающие» большие объемы текста. Его можно использовать для построения систем извлечения информации или понимания естественного языка или для предварительной обработки текста для глубокого обучения.

spaCy - это не исследовательское программное обеспечение. Он основан на последних исследованиях, но предназначен для работы любых разработчиков. Это приводит к совершенно иным проектным решениям, чем NLTK или CoreNLP, которые были созданы в качестве платформ для обучения и исследований. Сохранение небольшого размера меню позволяет spaCy в целом обеспечивать лучшую производительность и удобство для разработчиков.

Документация на английском языке: https://spacy.io/usage/spacy-101

Pattern

Pattern – это web-mining модуль, имеющий инструменты для интеллектуального анализа данных (Google, Twitter и Wikipedia API, веб-сканер, анализатор HTML DOM), обработки естественного языка (тегеры части речи, поиск n-граммов, анализ тональности, WordNet), машинного обучения (векторная модель, кластеризация, SVM), сетевого анализа и визуализации <canvas>.

Документация на английском языке: https://github.com/clips/pattern/wiki

Natasha

Natasha — качественное компактное решение для извлечения именованных сущностей из новостных статей на русском языке

Библиотека Natasha решает базовые задачи обработки естественного русского языка: сегментация на токены и предложения, морфологический и синтаксический анализ, лемматизация, извлечение именованных сущностей. Для новостных статей качество на всех задачах сравнимо или превосходит существующие решения. Библиотека поддерживает Python 3.5+ и PyPy3, не требует GPU, зависит только от NumPy.

Документация на английском языке:

https://github.com/natasha/ipymarkup

Googletrans

Googletrans – неофициальная и бесплатная библиотека для перевода текста Google Translate API на Python.

Документация на английском языке:

https://py-googletrans.readthedocs.io/en/latest/#

Yandex.Translate

Официальная библиотека для перевода текста от Yandex. Действовала до 2020 года, затем Yandex перестали выдавать бесплатные API ключи.

> **Note.** Starting May 27, 2020, free API keys aren't issued. We recommend using Yandex.Translate included in Yandex.Cloud, which supports the latest neural machine translation (NMT) technology.

Документация на английском языке:
https://yandex.com/dev/translate/doc/dg/concepts/about.html

Scikit-learn

Scikit-learn - один из наиболее широко используемых пакетов Python для Data Science и машинного обучения с открытым исходным кодом, основанный на NumPy и SciPy. Он позволяет выполнять множество операций и предоставляет множество алгоритмов. Scikit-Learn поддерживает предварительную обработку данных, уменьшение размерности, выбор модели, регрессии, классификации, кластерный анализ.

Документация на английском языке: https://scikit-learn.org/stable/

Transformers

Transformers — это библиотека на Python для обучения state-of-the-art моделей в обработке естественного языка. Разработкой библиотеки занимается компания HuggingFace. Transformers предоставляет API для использования таких архитектур трансформеров, как BERT, RoBERTa, GPT-2 или DistilBERT.

Архитектуры трансформера показывают наиболее точно решают задачи текстовой классификации, вычленения информации из текста, вопросно-ответных систем и текстовой генерации. Трансформеры в библиотеке предобучены и доступны в виде набора весов.

Transformers базируется на идее предобучения трансформер моделей. Трансформер модели доступны в разных формах, размерах и архитектурах. На вход трансформеры принимают данные в токенизированном формате.

Документация на английском языке: https://huggingface.co/transformers/

DeepPavlov

DeepPavlov — открытая программная библиотека разговорного AI для создания виртуальных диалоговых ассистентов и анализа текста.

На основе этой библиотеки вы можете собрать чат бота, ассистента или решение для анализа текста.

Документация на английском языке: http://docs.deeppavlov.ai/en/master/

Beautiful Soup

Beautiful Soup — это библиотека Python для извлечения данных из файлов HTML и XML, для парсинга. Она создаёт деревья считывания данных, позволяющие с лёгкостью эти данные получать. Но проблема с Beautiful Soup в том, что он не может выполнить всю работу самостоятельно. эта библиотека требует определенных модулей для работы.

Документация на русском языке:
https://www.crummy.com/software/BeautifulSoup/bs4/doc.ru/bs4ru.html#id11

Спасибо за внимание!

Русаков Алексей

vk.com/RusAlM t.me/RusAl84